

یادگیری ماشین

دکتر منصور رزقی

تمرین اول - پاسخ تمارین نظری

دانشکده علوم ریاضی، گروه علوم کامپیوتر، گرایش داده کاوی

۱ تمرین ۱: واریانس مجموع متغیرهای تصادفی

۱.۱ صورت مسئله

نشان دهید که برای دو متغیر تصادفی X و Y داریم:

$$\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y) \quad (۱)$$

۲.۱ حل

از تعریف واریانس شروع می‌کنیم:

$$\text{var}(X + Y) = \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 \quad (۲)$$

ابتدا جمله اول را بازنویسی می‌کنیم:

$$\begin{aligned} \mathbb{E}[(X + Y)^2] &= \mathbb{E}[X^2 + 2XY + Y^2] \\ &= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] \end{aligned} \quad (۳)$$

و جمله دوم:

$$\begin{aligned} (\mathbb{E}[X + Y])^2 &= (\mathbb{E}[X] + \mathbb{E}[Y])^2 \\ &= (\mathbb{E}[X])^2 + 2\mathbb{E}[X]\mathbb{E}[Y] + (\mathbb{E}[Y])^2 \end{aligned} \quad (۴)$$

حال با جایگذاری:

$$\begin{aligned} \text{var}(X + Y) &= \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2] \\ &\quad - (\mathbb{E}[X])^2 - 2\mathbb{E}[X]\mathbb{E}[Y] - (\mathbb{E}[Y])^2 \\ &= (\mathbb{E}[X^2] - (\mathbb{E}[X])^2) + (\mathbb{E}[Y^2] - (\mathbb{E}[Y])^2) \\ &\quad + 2(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]) \\ &= \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y) \end{aligned} \quad (۵)$$

۲ تمرین ۲: کاهش مسئله الاستیک نت به لاسو

۱.۲ صورت مسئله

نشان دهید که با تعریف:

$$J_1(\mathbf{w}) = \|\mathbf{y} - X\mathbf{w}\|_2^2 + \lambda_2 \|\mathbf{w}\|_2^2 + \lambda_1 \|\mathbf{w}\|_1 \quad (۶)$$

$$J_2(\mathbf{w}) = \|\tilde{\mathbf{y}} - \tilde{X}\mathbf{w}\|_2^2 + c\lambda_1 \|\mathbf{w}\|_1 \quad (۷)$$

که در آن $c = (1 + \lambda_2)^{-1/2}$ و:

$$\tilde{X} = c \begin{pmatrix} X \\ \sqrt{\lambda_2} I_d \end{pmatrix}, \quad \tilde{\mathbf{y}} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0}_{d \times 1} \end{pmatrix} \quad (۸)$$

آنگاه داریم:

$$\arg \min J_1(\mathbf{w}) = c (\arg \min J_2(\mathbf{w})) \quad (۹)$$

۲.۲ حل

ابتدا J_1 را بازنویسی می‌کنیم. حال با جایگذاری $\mathbf{w} = c\mathbf{u}$ (که در آن $c = (1 + \lambda_2)^{-1/2}$):

$$\begin{aligned} J_1(c\mathbf{u}) &= \|\mathbf{y} - Xc\mathbf{u}\|_2^2 + \lambda_2 \|c\mathbf{u}\|_2^2 + \lambda_1 \|c\mathbf{u}\|_1 \\ &= \|\mathbf{y} - cX\mathbf{u}\|_2^2 + \lambda_2 c^2 \|\mathbf{u}\|_2^2 + c\lambda_1 \|\mathbf{u}\|_1 \end{aligned} \quad (۱۰)$$

اکنون جمله اول را بسط می‌دهیم. می‌دانیم که:

$$\begin{aligned} \|\mathbf{y} - cX\mathbf{u}\|_2^2 + \lambda_2 c^2 \|\mathbf{u}\|_2^2 &= \left\| \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \end{pmatrix} - \begin{pmatrix} cX \\ c\sqrt{\lambda_2} I_d \end{pmatrix} \mathbf{u} \right\|_2^2 \\ &= \|\tilde{\mathbf{y}} - \tilde{X}\mathbf{u}\|_2^2 \end{aligned} \quad (۱۱)$$

بنابراین:

$$J_1(c\mathbf{u}) = \|\tilde{\mathbf{y}} - \tilde{X}\mathbf{u}\|_2^2 + c\lambda_1 \|\mathbf{u}\|_1 = J_2(\mathbf{u}) \quad (۱۲)$$

در نتیجه می‌توان مسئله الاستیک نت را با حل‌کننده لاسو برای داده‌های تغییر یافته حل کرد.

۳ تمرین ۳: مدل برنولی-گوسی و منظم سازی ℓ_0

۱.۳ صورت مسئله

توضیح دهید چگونه مدل برنولی-گوسی (Bernoulli-Gaussian) prior برای وزن های w_i منجر به استفاده از نرم ℓ_0 به عنوان منظم سازی می شود.

۲.۳ حل

فرض کنید برای هر وزن w_i داریم:

$$w_i = \begin{cases} \mathcal{N}(0, \sigma^2) & \text{با احتمال } \pi \\ 0 & \text{با احتمال } 1 - \pi \end{cases} \quad (۱۳)$$

می توان این را به صورت زیر نوشت:

$$p(w_i) = (1 - \pi)\delta(w_i) + \pi\mathcal{N}(w_i|0, \sigma^2) \quad (۱۴)$$

که در آن δ تابع دلتای دیراک است.

با استفاده از رویکرد Maximum MAP (Posteriori):

$$\begin{aligned} \hat{\mathbf{w}} &= \arg \max_{\mathbf{w}} p(\mathbf{w}|\mathbf{y}) \\ &= \arg \max_{\mathbf{w}} p(\mathbf{y}|\mathbf{w})p(\mathbf{w}) \\ &= \arg \max_{\mathbf{w}} \log p(\mathbf{y}|\mathbf{w}) + \log p(\mathbf{w}) \end{aligned} \quad (۱۵)$$

برای prior داریم:

$$\log p(\mathbf{w}) = \sum_i \log p(w_i) \quad (۱۶)$$

برای π کوچک، وقتی $w_i \neq 0$ ، جریمه ای ثابت به ازای هر وزن غیرصفر اضافه می شود. در نتیجه:

$$\log p(\mathbf{w}) \approx -\lambda \|\mathbf{w}\|_0 \quad (۱۷)$$

که $\|\mathbf{w}\|_0$ تعداد عناصر غیرصفر \mathbf{w} است.

نتیجه: مدل برنولی-گوسی منجر به منظم سازی ℓ_0 می شود که تعداد وزن های غیرصفر را جریمه می کند.

۴ تمرین ۴: پرسش مفهومی دربارهٔ لاسو و ریج

۱.۴ چرا ℓ_1 منجر به sparse شدن می‌شود؟

۱.۱.۴ دیدگاه هندسی

در بهینه‌سازی مقید:

$$\min \|y - Xw\|_2^2 \quad \text{s.t.} \quad \|w\|_1 \leq t \quad (18)$$

ناحیهٔ قابل قبول برای ℓ_1 (الماس در ۲ بعد) دارای گوشه‌های تیز روی محورها است. سطوح هم‌ارز تابع هدف (بیضی‌ها) معمولاً در این گوشه‌ها با ناحیهٔ مجاز برخورد می‌کنند، که این نقاط دارای مختصات صفر هستند. در مقابل، ℓ_2 (دایره/کره) گوشهٔ تیزی ندارد و کمتر منجر به صفر شدن دقیق ضرایب می‌شود.

۲.۱.۴ دیدگاه احتمالاتی

• منظم‌ساز ℓ_1 : معادل prior Laplace است:

$$p(w_i) \propto \exp(-\lambda|w_i|)$$

• منظم‌ساز ℓ_2 : معادل prior Gaussian است:

$$p(w_i) \propto \exp(-\lambda w_i^2)$$

توزیع Laplace در صفر دارای چگالی بیشتر و دمه‌های سنگین‌تر است، پس ترجیح می‌دهد بسیاری از وزن‌ها دقیقاً صفر باشند.

۲.۴ کاربردهای sparsity

- انتخاب ویژگی: شناسایی مهم‌ترین ویژگی‌ها
- تفسیرپذیری: مدل ساده‌تر با تعداد کمتر متغیر
- کاهش overfitting: کم کردن پیچیدگی مدل
- کاهش هزینهٔ محاسباتی: ذخیره‌سازی و محاسبهٔ سریع‌تر

۳.۴ تحلیل ℓ_2 (Ridge)

منظم‌ساز ℓ_2 :

- وزن‌ها را کوچک می‌کند ولی به‌ندرت دقیقاً صفر می‌شوند
- برای مسائل ill-conditioned مناسب است
- در حضور multicollinearity عملکرد بهتری دارد
- دارای جواب closed-form است
- همهٔ ویژگی‌ها را نگه می‌دارد (غیر-sparse)